

# Curs 13

Cristian Niculescu

## 1 Repartiții beta

### 1.1 Scopurile învățării

1. Să se familiarizeze cu familia cu 2 parametri a repartițiilor beta și cu normalizarea ei.
2. Să poată să actualizeze o a priori beta la o a posteriori beta în cazul unei verosimilități binomiale.

### 1.2 Repartiția beta

**Repartiția beta**  $\text{beta}(a, b)$  este o repartiție cu 2 parametri cu domeniul  $[0, 1]$  și pdf

$$f(\theta) = \frac{(a+b-1)!}{(a-1)!(b-1)!} \theta^{a-1} (1-\theta)^{b-1}.$$

Următoarea aplicație ne permite să explorăm forma repartiției Beta când parametrii variază:

<http://mathlets.org/mathlets/beta-distribution/>.

Repartiția beta poate fi definită pentru orice numere reale  $a > 0$  și  $b > 0$ . Am definit-o doar pentru  $a, b \in \mathbb{N}^*$ , dar puteți vedea întreaga istorie aici:

[http://en.wikipedia.org/wiki/Beta\\_distribution](http://en.wikipedia.org/wiki/Beta_distribution).

În contextul actualizării bayesiene,  $a$  și  $b$  sunt numiți adesea **hiperparametri** pentru a-i deosebi de parametrul necunoscut  $\theta$  care reprezintă ipoteza noastră. Într-un anumit sens,  $a$  și  $b$  sunt la "un nivel mai sus" decât  $\theta$ , deoarece ei parametrizează pdf.

#### 1.2.1 O observație simplă, dar importantă

Dacă o pdf  $f(\theta)$  are forma  $c\theta^{a-1}(1-\theta)^{b-1}$ , atunci  $f(\theta)$  este pdf a unei repartiții  $\text{beta}(a, b)$  și constanta de normalizare trebuie să fie

$$c = \frac{(a+b-1)!}{(a-1)!(b-1)!}.$$

Aceasta rezultă deoarece constanta  $c$  trebuie să normalizeze pdf pentru a avea probabilitatea totală 1. Există doar o asemenea constantă și ea este dată în formula pentru repartiția beta.

O observație similară este valabilă pentru repartițiile normală, exponențială, etc.

### 1.2.2 A priori și a posteriori beta pentru variabile aleatoare binomiale

**Exemplul 1.** Presupunem că avem o monedă cu probabilitate necunoscută  $\theta$  a aversului. Aruncăm moneda de 12 ori și obținem 8 aversuri și 4 reversuri. Plecând cu o a priori plată, arătați că pdf a posteriori este o repartiție beta(9, 5).

**Răspuns.** Notăm cu  $x_1$  datele din cele 12 aruncări. În tabelul următor numim  $c_2$  factorul constant din coloana a posteriori. Observația noastră simplă ne va spune că acesta trebuie să fie factorul constant din pdf beta.

Datele sunt 8 aversuri și 4 reversuri. Deoarece acestea vin dintr-o repartiție binomială(12,  $\theta$ ), verosimilitatea este  $p(x_1|\theta) = C_{12}^8 \theta^8 (1 - \theta)^4$ . Astfel, tabelul de actualizare Bayesiană este

hypothesis	prior	likelihood	Bayes numerator	posterior
$\theta$	$1 \cdot d\theta$	$\binom{12}{8} \theta^8 (1 - \theta)^4$	$\binom{12}{8} \theta^8 (1 - \theta)^4 d\theta$	$c_2 \theta^8 (1 - \theta)^4 d\theta$
total	1		$T = \binom{12}{8} \int_0^1 \theta^8 (1 - \theta)^4 d\theta$	1

Observația noastră simplă de mai sus are loc cu  $a = 9$  și  $b = 5$ . De aceea pdf a posteriori

$$f(\theta|x_1) = c_2 \theta^8 (1 - \theta)^4$$

are o repartiție beta(9, 5) și constanta de normalizare  $c_2$  trebuie să fie

$$c_2 = \frac{13!}{8! \cdot 4!}.$$

Notă. Am inclus explicit coeficientul binomial  $C_{12}^8$  în verosimilitate. Puteam să-l notăm cu  $c_1$  și să nu-i dăm valoarea explicită.

**Exemplul 2.** Acum presupunem că aruncăm aceeași monedă din nou, obținând  $n$  aversuri și  $m$  reversuri. Folosind pdf a posteriori din exemplul precedent ca noua noastră pdf a priori, arătați că noua pdf a posteriori este cea a unei repartiții beta(9 +  $n$ , 5 +  $m$ ).

**Răspuns.** Totul este în tabel. Vom numi  $x_2$  datele acestor  $n + m$  aruncări adiționale. De această dată nu vom mai face explicit coeficientul binomial. În loc de aceasta îl vom nota cu  $c_3$ . Ori de câte ori avem nevoie de o nouă

etichetă vom folosi  $c$  cu un nou indice. În loc de "Bayes posterior" se va citi "numărătorul Bayes", iar în loc de "numerator" se va citi "a posteriori".

hyp.	prior	likelihood	Bayes posterior	numerator
$\theta$	$c_2 \theta^8 (1 - \theta)^4 d\theta$	$c_3 \theta^n (1 - \theta)^m$	$c_2 c_3 \theta^{n+8} (1 - \theta)^{m+4} d\theta$	$c_4 \theta^{n+8} (1 - \theta)^{m+4} d\theta$
total	1	$T = \int_0^1 c_2 c_3 \theta^{n+8} (1 - \theta)^{m+4} d\theta$		1

Din nou observația noastră simplă are loc și, de aceea, pdf a posteriori

$$f(\theta|x_1, x_2) = c_4 \theta^{n+8} (1 - \theta)^{m+4}$$

este cea a unei repartiții beta( $n + 9, m + 5$ ).

**Observație.** **Beta plată.** Repartiția beta(1, 1) coincide cu repartiția uniformă pe  $[0, 1]$ , pe care am numit-o de asemenea a priori plată pentru  $\theta$ . Aceasta rezultă înlocuind  $a = 1$  și  $b = 1$  în definiția repartiției beta, dând  $f(\theta) = 1$ .

**Rezumat.** Dacă probabilitatea aversului este  $\theta$ , numărul de aversuri în  $n + m$  aruncări are o repartiție binomială( $n + m, \theta$ ). Am văzut că dacă a priori pentru  $\theta$  este o repartiție beta, atunci la fel este și a posteriori; doar parametrii  $a$  și  $b$  ai repartiției beta se schimbă! Rezumăm precis cum se schimbă într-un tabel. Presupunem că datele sunt  $n$  aversuri în  $n + m$  aruncări.

hypothesis	data	prior	likelihood	posterior
$\theta$	$x = n$	beta( $a, b$ )	binomial( $n + m, \theta$ )	beta( $a + n, b + m$ )
$\theta$	$x = n$	$c_1 \theta^{a-1} (1 - \theta)^{b-1} d\theta$	$c_2 \theta^n (1 - \theta)^m$	$c_3 \theta^{a+n-1} (1 - \theta)^{b+m-1} d\theta$

### 1.2.3 A priori conjugate

Repartiția beta este numită o **a priori conjugată** pentru repartiția binomială. Aceasta înseamnă că, dacă funcția de verosimilitate este binomială, atunci o a priori beta dă o a posteriori beta. De fapt, repartiția beta este o a priori conjugată și pentru repartițiile Bernoulli și geometrică.

Un alt exemplu important: repartiția normală își este propria a priori conjugată. În particular, dacă funcția de verosimilitate este normală cu dispersie cunoscută, atunci o a priori normală dă o a posteriori normală.

A priori conjugate sunt utile deoarece reduc actualizarea Bayesiană la modificarea parametrilor repartiției a priori (așa numiții hiperparametri) în locul calculului integralelor. Am văzut asta pentru repartiția beta în ultimul tabel. Pentru mult mai multe exemple: [http://en.wikipedia.org/wiki/Conjugate\\_prior\\_distribution](http://en.wikipedia.org/wiki/Conjugate_prior_distribution).

## 2 Date continue cu a priori continue

### 2.1 Scopurile învățării

1. Să poată construi un tabel de actualizare Bayesiană pentru ipoteze continue și date continue.
2. Să poată recunoaște pdf a unei repartiții normale și să determine media și dispersia ei.

### 2.2 Introducere

Facem actualizare Bayesiană când atât ipotezele cât și datele iau valori continue. Modelul este același cu ce-am făcut înainte; vom recapitula mai întâi celelalte 2 cazuri.

### 2.3 Cazurile anterioare

#### 2.3.1 Ipoteze discrete, date discrete

##### Notății

Ipoteze  $\mathcal{H}$

Date  $x$

A priori  $P(\mathcal{H})$

Verosimilitatea  $p(x|\mathcal{H})$

A posteriori  $P(\mathcal{H}|x)$ .

**Exemplul 1.** Presupunem că avem datele  $x$  și 3 posibile explicații (ipoteze) pentru date, pe care le vom numi  $A, B, C$ . De asemenea presupunem că datele pot lua 2 valori posibile,  $-1$  și  $1$ .

Pentru a folosi datele pentru estimarea probabilităților diverselor ipoteze, avem nevoie de o pmf a priori și un tabel de verosimilitate. Presupunem că a priori și verosimilitățile sunt date în următoarele tabele.

hypothesis $\mathcal{H}$	prior $P(\mathcal{H})$
A	0.1
B	0.3
C	0.6

Probabilități a priori

hypothesis $\mathcal{H}$	likelihood $p(x \mathcal{H})$	
	$x = -1$	$x = 1$
A	0.2	0.8
B	0.5	0.5
C	0.7	0.3

Verosimilități

Fiecare element din tabelul de verosimilitate este o verosimilitate  $p(x|\mathcal{H})$ . De exemplu,  $p(x = -1|A) = 0.2$ .

**Întrebare:** Presupunem că obținem datele  $x_1 = 1$ . Folosiți aceasta pentru

a obține probabilitățile a posteriori pentru ipoteze.

**Răspuns.** Datele aleg o coloană din tabelul de verosimilități pe care o folosim apoi în tabelul nostru de actualizare Bayesiană.

hypothesis	prior	likelihood	Bayes	
			numerator	posterior
$\mathcal{H}$	$P(\mathcal{H})$	$p(x = 1   \mathcal{H})$	$p(x   \mathcal{H})P(\mathcal{H})$	$P(\mathcal{H}   x) = \frac{p(x   \mathcal{H})P(\mathcal{H})}{p(x)}$
$A$	0.1	0.8	0.08	0.195
$B$	0.3	0.5	0.15	0.366
$C$	0.6	0.3	0.18	0.439
total	1		$p(x) = 0.41$	1

Pentru a rezuma: probabilitățile a priori ale ipotezelor și verosimilitățile datelor cunoscând ipotezele au fost date; numărătorul Bayes este produsul dintre a priori și verosimilitate; probabilitatea totală  $p(x)$  este suma probabilităților din coloana numărătorilor Bayes; împărțim la  $p(x)$  pentru a normaliza numărătorii Bayes.

### 2.3.2 Ipoteze continue, date discrete

Acum presupunem că avem datele  $x$  care pot lua o mulțime discretă de valori și un parametru continuu  $\theta$  care determină repartiția din care sunt extrase datele.

#### Notății

Ipoteze  $\theta$

Date  $x$

A priori  $f(\theta)d\theta$

Verosimilitate  $p(x|\theta)$

A posteriori  $f(\theta|x)d\theta$ .

Notă: Am înmulțit cu  $d\theta$  pentru a exprima a priori și a posteriori ca probabilități. Ca densități, avem pdf a priori  $f(\theta)$  și pdf a posteriori  $f(\theta|x)$ .

**Exemplul 2.** Presupunem că  $x \sim \text{Binomial}(5, \theta)$ . Deci  $\theta$  este în domeniul  $[0, 1]$  și datele  $x$  pot lua 6 valori posibile, 0, 1, ..., 5.

Deoarece există un domeniu continuu de valori, folosim o pdf pentru a descrie a priori pentru  $\theta$ . Presupunem că a priori este  $f(\theta) = 2\theta$ . Putem face totuși un tabel de verosimilitate, cu toate că are o singură linie, reprezentând o ipoteză arbitrară  $\theta$ .

hypothesis	likelihood $p(x   \theta)$					
	$x = 0$	$x = 1$	$x = 2$	$x = 3$	$x = 4$	$x = 5$
$\theta$	$\binom{5}{0}(1 - \theta)^5$	$\binom{5}{1}\theta(1 - \theta)^4$	$\binom{5}{2}\theta^2(1 - \theta)^3$	$\binom{5}{3}\theta^3(1 - \theta)^2$	$\binom{5}{4}\theta^4(1 - \theta)$	$\binom{5}{5}\theta^5$

Verosimilități

**Întrebare** Presupunem că obținem data  $x_1 = 2$ . Folosiți aceasta pentru a afla pdf a posteriori pentru parametrul (ipoteza)  $\theta$ .

**Răspuns.** Ca mai înainte, data alege una din coloanele din tabelul de verosimilități pe care o putem folosi în tabelul nostru de actualizare Bayesiană. Deoarece vrem să lucrăm cu probabilități scriem  $f(\theta)d\theta$  și  $f(\theta|x_1)d\theta$ . Pe ultima linie, în loc de " $\theta^2$ " se va citi " $\theta^3$ ". Pe ultima coloană, în loc de " $\frac{3!3!}{7!}$ " se va citi " $\frac{7!}{3!3!}$ ".

hypothesis	prior	likelihood	Bayes numerator	posterior
$\theta$	$f(\theta) d\theta$	$p(x = 2   \theta)$	$p(x   \theta)f(\theta) d\theta$	$f(\theta   x) d\theta = \frac{p(x   \theta)f(\theta) d\theta}{p(x)}$
$\theta$	$2\theta d\theta$	$\binom{5}{2}\theta^2(1-\theta)^3$	$2\binom{5}{2}\theta^3(1-\theta)^3 d\theta$	$f(\theta   x) d\theta = \frac{3!3!}{7!}\theta^3(1-\theta)^3 d\theta$
total	1	$p(x) = \int_0^1 2\binom{5}{2}\theta^2(1-\theta)^3 d\theta = 2\binom{5}{2}\frac{3!3!}{7!}$		1

Pentru a rezuma: probabilitățile a priori ale ipotezelor și verosimilitățile datelor cunoscând ipotezele sunt date; numărătorul Bayes este produsul dintre a priori și verosimilitate; probabilitatea totală  $p(x)$  este integrala probabilităților din coloana numărătorului Bayes; împărțim prin  $p(x)$  pentru a normaliza numărătorul Bayes.

## 2.4 Ipoteze continue și date continue

Când atât datele și ipotezele sunt continue, singura schimbare în exemplul anterior este că funcția de verosimilitate folosește o pdf  $f(x|\theta)$  în locul unei pmf  $p(x|\theta)$ . Forma generală a tabelului de actualizare Bayesiană este aceeași.

**Notății**

Ipoteze  $\theta$

Date  $x$

A priori  $f(\theta)d\theta$

Verosimilitate  $f(x|\theta)dx$

A posteriori  $f(\theta|x)d\theta$ .

**Simplificarea notației.** În cazurile precedente am inclus  $d\theta$  astfel că lucrăm cu probabilități în loc de densități. Când atât datele cât și ipotezele sunt continue, vom avea nevoie atât de  $d\theta$  cât și de  $dx$ . Aceasta face lucrurile mai simple conceptual, dar mai greoaie notațional. Pentru a simplifica notația ne vom permite să eliminăm  $dx$  din tabelele noastre. Aceasta este în regulă, deoarece datele  $x$  sunt fixate. Vom păstra  $d\theta$  deoarece ipotezei  $\theta$  i se permite să varieze.

Pentru comparație, întâi arătăm tabelul general cu notație simplificată, urmat imediat apoi de tabelul arătând infintezimalele. La primul tabel. pe ultima coloană, în loc de " $f(\theta|x)$ " se va citi " $f(\theta|x)d\theta$ ".

hypoth.	prior	likelihood	Bayes numerator	posterior
$\theta$	$f(\theta) d\theta$	$f(x \theta)$	$f(x \theta)f(\theta) d\theta$	$f(\theta x) = \frac{f(x \theta)f(\theta) d\theta}{f(x)}$
total	1	$f(x) = \int f(x \theta)f(\theta) d\theta$		1

Tabel de actualizare Bayesiană fără  $dx$

hypoth.	prior	likelihood	Bayes numerator	posterior
$\theta$	$f(\theta) d\theta$	$f(x \theta) dx$	$f(x \theta)f(\theta) d\theta dx$	$f(\theta x) d\theta = \frac{f(x \theta)f(\theta) d\theta dx}{f(x) dx} = \frac{f(x \theta)f(\theta) d\theta}{f(x)}$
total	1	$f(x) dx = (\int f(x \theta)f(\theta) d\theta) dx$		1

Tabel de actualizare Bayesiană cu  $d\theta$  și  $dx$

Pentru a rezuma: probabilitățile a priori ale ipotezelor și verosimilitățile datelor cunoscând ipotezele erau date; numărătorul Bayes este produsul dintre a priori și verosimilitate; probabilitatea totală  $f(x)dx$  este integrala probabilităților din coloana numărătorului Bayes; împărțim prin  $f(x)dx$  pentru a normaliza numărătorul Bayes.

## 2.5 Ipoteză normală, date normale

Un exemplu standard de ipoteze continue și date continue presupune că atât datele cât și a priori au repartiții normale. Următorul exemplu presupune că dispersia datelor este cunoscută.

**Exemplul 3.** Presupunem că avem data  $x = 5$  care a fost extrasă dintr-o repartiție normală cu medie necunoscută  $\theta$  și deviație standard 1.

$$x \sim N(\theta, 1).$$

Presupunem mai departe că repartiția noastră a priori pentru  $\theta$  este  $\theta \sim N(2, 1)$ .

Fie  $x$  o valoare arbitrară a datelor.

- Faceți un tabel Bayesian cu a priori, verosimilitate și numărător Bayes.
- Arătați că repartiția a posteriori pentru  $\theta$  este tot normală.

c) Aflați media și dispersia repartiției a posteriori.

**Răspuns.** Cum am făcut cu tabelele de mai sus, un bun compromis asupra notației este să includem  $d\theta$ , dar nu  $dx$ . Motivul pentru aceasta este că probabilitatea totală este calculată integrând după  $\theta$  și  $d\theta$  ne reamintește asta.

Pdf a priori a noastră este

$$f(\theta) = \frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2}.$$

Funcția de verosimilitate este

$$f(x=5|\theta) = \frac{1}{\sqrt{2\pi}} e^{-(5-\theta)^2/2}.$$

Înmulțim a priori cu verosimilitatea.

$$\begin{aligned} \text{a priori} \cdot \text{verosimilitatea} &= \frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2} \cdot \frac{1}{\sqrt{2\pi}} e^{-(5-\theta)^2/2} \\ &= \frac{1}{2\pi} e^{-(2\theta^2 - 14\theta + 29)/2} \\ &= \frac{1}{2\pi} e^{-(\theta^2 - 7\theta + 29/2)} \quad (\text{completăm pătratul}) \\ &= \frac{1}{2\pi} e^{-((\theta-7/2)^2 + 9/4)} \\ &= \frac{e^{-9/4}}{2\pi} e^{-(\theta-7/2)^2} \\ &= c_1 e^{-(\theta-7/2)^2}. \end{aligned}$$

La ultimul pas am înlocuit factorul constant complicat cu expresia mai simplă  $c_1$ . Pe linia a 3-a a tabelului, în loc de " $e^{-(\theta-7/2)^2}$ " se va citi " $e^{-(\theta-7/2)^2} d\theta$ " (de 2 ori).

hypothesis	prior	likelihood	Bayes numerator	posterior $f(\theta   x=5) d\theta$
$\theta$	$f(\theta) d\theta$	$f(x=5 \theta)$	$f(x=5 \theta)f(\theta) d\theta$	$\frac{f(x=5 \theta)f(\theta) d\theta}{f(x=5)}$
$\theta$	$\frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2} d\theta$	$\frac{1}{\sqrt{2\pi}} e^{-(5-\theta)^2/2}$	$c_1 e^{-(\theta-7/2)^2}$	$c_2 e^{-(\theta-7/2)^2}$
total	1		$f(x=5) = \int f(x=5 \theta)f(\theta) d\theta$	1


Pdf a posteriori este cea a unei repartiții normale. Deoarece exponențiala unei repartiții normale este  $e^{-(\theta-\mu)^2/2\sigma^2}$ , avem media  $\mu = 7/2$  și  $2\sigma^2 = 1$ , deci



dispersia este  $\sigma^2 = 1/2$ .

Nu trebuie să calculăm probabilitatea totală; ea este folosită doar pentru normalizare și știm deja constanta de normalizare  $\frac{1}{\sigma\sqrt{2\pi}}$  pentru o repartiție normală.

Iată graficele pdf-urilor a priori și a posteriori. Observăm cum data "trage" a priori spre ea.



a priori = albastru; a posteriori = mov; data = roșu

Acum, repetăm exemplul precedent pentru  $x$  general.

**Exemplul 4.** Presupunem că data noastră  $x$  este extrasă dintr-o repartiție normală cu medie necunoscută  $\theta$  și deviație standard 1.

$$x \sim N(\theta, 1).$$

**Răspuns.** Pdf a priori și funcția de verosimilitate sunt

$$f(\theta) = \frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2}, \quad f(x|\theta) = \frac{1}{\sqrt{2\pi}} e^{-(x-\theta)^2/2}.$$

Numărătorul Bayes este produsul dintre a priori și verosimilitate:

$$\begin{aligned}
 \text{a priori} \cdot \text{verosimilitatea} &= \frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2} \cdot \frac{1}{\sqrt{2\pi}} e^{-(x-\theta)^2/2} \\
 &= \frac{1}{2\pi} e^{-(2\theta^2 - (4+2x)\theta + 4+x^2)/2} \\
 &= \frac{1}{2\pi} e^{-(\theta^2 - (2+x)\theta + (4+x^2)/2)} \quad (\text{completăm pătratul}) \\
 &= \frac{1}{2\pi} e^{-((\theta - (1+x/2))^2 - (1+x/2)^2 + (4+x^2)/2)} \\
 &= c_1 e^{-(\theta - (1+x/2))^2}.
 \end{aligned}$$

Ca în ultimul exemplu, în ultimul pas am înlocuit toate constantele, inclusiv exponențialele care implică doar pe  $x$ , prin simpla constantă  $c_1$ .

Acum, tabelul Bayesian de înlocuire devine (pe linia a 3-a a tabelului, în loc de " $e^{-(\theta - (1+x/2))^2}$ " se va citi " $e^{-(\theta - (1+x/2))^2} d\theta$ " (de 2 ori)).

hypothesis	prior	likelihood	Bayes numerator	posterior $f(\theta   x) d\theta$
$\theta$	$f(\theta) d\theta$	$f(x   \theta)$	$f(x   \theta) f(\theta) d\theta$	$\frac{f(x   \theta) f(\theta) d\theta}{f(x)}$
$\theta$	$\frac{1}{\sqrt{2\pi}} e^{-(\theta-2)^2/2} d\theta$	$\frac{1}{\sqrt{2\pi}} e^{-(x-\theta)^2/2}$	$c_1 e^{-(\theta - (1+x/2))^2}$	$c_2 e^{-(\theta - (1+x/2))^2}$
total	1	$f(x) = \int f(x   \theta) f(\theta) d\theta$		1

Ca în exemplul precedent putem vedea din forma a posteriori că ea trebuie să fie a unei repartiții normale cu media  $1 + x/2$  și dispersia  $1/2$ . (Comparați aceasta cu cazul  $x = 5$  din exemplul precedent.)

## 2.6 Probabilități predictive

Deoarece datele  $x$  sunt continue, au pdf-uri predictive a priori și a posteriori. Pdf predictivă a priori este densitatea de probabilitate totală calculată la marginea de jos a coloanei numărătorului Bayes:

$$f(x) = \int f(x|\theta) f(\theta) d\theta,$$

unde integrala este calculată pe întregul domeniu al lui  $\theta$ .

Pdf predictivă a posteriori are aceeași formă ca pdf predictivă a priori, cu excepția faptului că folosește probabilitățile a posteriori pentru  $\theta$ :

$$f(x_2|x_1) = \int f(x_2|\theta, x_1) f(\theta|x_1) d\theta.$$

Ca de obicei, presupunem că  $x_1$  și  $x_2$  sunt **condiționat independente**. Adică,

$$f(x_2|\theta, x_1) = f(x_2|\theta).$$

În acest caz formula pentru pdf predictivă a posteriori este un pic mai simplă:

$$f(x_2|x_1) = \int f(x_2|\theta)f(\theta|x_1)d\theta.$$