

Curs 17

Cristian Niculescu

1 Testarea semnificației ipotezei 0 III

1.1 Scopurile învățării

1. Fiind date ipotezele și datele, să poată identifica un test de semnificație potrivit dintr-o listă de teste uzuale.
2. Fiind date ipotezele, datele și un test de semnificație sugerat, să știe cum să caute detaliile și să aplice testul.

1.2 Introducere

Toate testele de semnificație au același model de bază în proiectarea și implementarea lor.

Proiectarea unui test al semnificației ipotezei 0 (NHST):

Specificăm ipoteza 0 și ipotezele alternative.

Alegem o statistică a testului ale cărei repartiție 0 și repartiție alternativă (repartiții alternative) sunt cunoscute.

Specificăm o regiune de respingere. Cel mai adesea acest lucru este făcut implicit specificând un nivel de semnificație α și o metodă pentru calculul p -valorilor bazată pe cozile repartiției 0.

Calculăm puterea folosind repartiția alternativă (repartițiile alternative).

Folosirea unui NHST:

Colectăm datele și calculăm statistica testului.

Verificăm dacă statistica testului este în regiunea de respingere. Cel mai adesea acest lucru este făcut implicit verificând dacă $p < \alpha$. Dacă este așa, ”respingem ipoteza 0 în favoarea ipotezei alternative”. Altfel concluzionăm ”datele nu sprijină respingerea ipotezei 0”.

Observați formularea prudentă: când eșuăm în a respinge H_0 , nu concluzionăm că H_0 este adevărată. Eșecul respingerii poate avea alte cauze. De exemplu, poate nu avem destule date pentru a distinge clar H_0 și H_A , în timp ce mai multe date ar indica respingerea lui H_0 .

1.3 Parametrii populației și statistici de selecție

Exemplul 1. Dacă alegem aleator 10 bărbați dintr-o populație și le măsurăm înălțimile, spunem că **am selectat înălțimile** din populație. În acest caz **media de selecție**, să spunem \bar{x} , este media înălțimilor selectate. Este o statistică și îi știm explicit valoarea. Pe de altă parte, adevărata înălțime medie a populației, să spunem μ , este necunoscută și putem doar să estimăm valoarea ei. Numim μ **parametru al populației**.

Principalul scop al testării semnificației este folosirea statisticilor de selecție pentru a trage concluzii despre parametri de selecție. De exemplu, putem testa dacă înălțimea medie a bărbaților dintr-o populație dată este mai mare ca 1.78 m.

1.4 O galerie a testelor de semnificație uzuale legate de repartiția normală

Toate aceste teste presupun **date normale**.

Repartițiile 0 pentru aceste teste sunt **toate legate de repartiția normală** prin formule explicite. Argumentele sunt accesibile oricui știe analiză matematică și este interesat de înțelegerea lor. Dat fiind numele oricărei repartiții, putem căuta online detaliile construcției și proprietăților ei. De asemenea putem folosi R pentru a explora repartiția numeric și grafic.

Când analizăm datele cu oricare din aceste teste, un lucru de importanță cheie este să verificăm că presupunerile sunt adevărate sau cel puțin aproximativ adevărate. De exemplu, nu ar trebui să folosim un test care presupune că datele sunt normale până nu am verificat că datele sunt aproximativ normale.

1.4.1 Testul z

Utilizare: Testăm dacă media populației este egală cu o medie ipotetică.

Date: x_1, x_2, \dots, x_n .

Presupuneri: Datele sunt selecții normale independente:

$$x_i \sim N(\mu, \sigma^2) \text{ unde } \mu \text{ este necunoscută, dar } \sigma \text{ este cunoscută.}$$

H_0 : Pentru un μ_0 specificat, $\mu = \mu_0$.

H_A :

Bilaterală: $\mu \neq \mu_0$;

unilaterală mai mare: $\mu > \mu_0$;

unilaterală mai mică: $\mu < \mu_0$.

Statistica testului: $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$.

Repartiția 0: $f(z|H_0)$ este pdf a lui $Z \sim N(0, 1)$.

valoarea p :

Bilaterală:	$p = P(Z > z)$	$= 2 * (1 - \text{pnorm}(\text{abs}(z), 0, 1));$
unilaterală mai mare:	$p = P(Z > z)$	$= 1 - \text{pnorm}(z, 0, 1);$
unilaterală mai mică:	$p = P(Z < z)$	$= \text{pnorm}(z, 0, 1).$

Codul R: Nu pare a fi o singură funcție R pentru a folosi un test z . Desigur, se poate folosi R pentru a calcula z și valoarea p .

Exemplul 2. Vezi exemplul 13 din cursul 16.

1.4.2 Testul t de o selecție pentru medie

Utilizare: Testăm dacă media populației este egală cu o medie ipotetică.

Date: x_1, x_2, \dots, x_n .

Presupuneri: Datele sunt selecții normale independente:

$x_i \sim N(\mu, \sigma^2)$ unde atât μ cât și σ sunt necunoscute.

H_0 : Pentru un μ_0 specificat, $\mu = \mu_0$.

H_A :

Bilaterală:	$\mu \neq \mu_0;$
unilaterală mai mare:	$\mu > \mu_0;$
unilaterală mai mică:	$\mu < \mu_0.$

Statistica testului: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$,

unde s^2 este dispersia de selecție: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Repartiția 0: $f(t|H_0)$ este pdf a lui $T \sim t(n-1)$ (repartiția t a lui Student cu $n-1$ grade de libertate).

Valoarea p :

Bilaterală:	$p = P(T > t)$	$= 2 * (1 - \text{pt}(\text{abs}(t), n - 1));$
unilaterală mai mare:	$p = P(T > t)$	$= 1 - \text{pt}(t, n - 1);$
unilaterală mai mică:	$p = P(T < t)$	$= \text{pt}(t, n - 1).$

Exemplu de cod R: Pentru datele $x = 1, 3, 5, 7, 2$ putem face un test t de o selecție cu $H_0: \mu = 2.5$ folosind comenzile în R:

```
x=c(1,3,5,7,2)
```

```
t.test(x, mu=2.5)
```

Acestea vor da câteva informații, incluzând media datelor, valoarea t și valoarea p bilaterală. Vezi ajutorul pentru această funcție pentru alte setări ale argumentelor.

Exemplul 3. Vezi exemplul 2 din partea a 2-a a cursului 16.

1.4.3 Testul t cu 2 selecții pentru compararea mediilor

Cazul dispersiilor egale

Începem descriind testul [presupunând dispersii egale](#).

Utilizare: Testăm dacă mediile populației din 2 populații diferă printr-o cantitate ipotetică.

Date: x_1, x_2, \dots, x_n și y_1, y_2, \dots, y_m .

Presupuneri: Ambele grupe de date sunt selecții normale independente:

$$\begin{aligned}x_i &\sim N(\mu_x, \sigma^2), \\y_j &\sim N(\mu_y, \sigma^2),\end{aligned}$$

unde atât μ_x cât și μ_y sunt necunoscute și posibil diferite. Dispersia σ^2 este necunoscută, dar aceeași pentru ambele grupe.

H_0 : Pentru un μ_0 specificat: $\mu_x - \mu_y = \mu_0$.

H_A :

$$\begin{aligned}\text{Bilaterală:} & \mu_x - \mu_y \neq \mu_0; \\ \text{unilaterală mai mare:} & \mu_x - \mu_y > \mu_0; \\ \text{unilaterală mai mică:} & \mu_x - \mu_y < \mu_0.\end{aligned}$$

Statistica testului: $t = \frac{\bar{x} - \bar{y} - \mu_0}{s_p}$, unde s_x^2 și s_y^2 sunt dispersiile de selecție ale datelor x , respectiv y și s_p^2 este (uneori numită) dispersia de selecție combinată:

$$s_p^2 = \frac{(n-1)s_x^2 + (m-1)s_y^2}{n+m-2} \left(\frac{1}{n} + \frac{1}{m} \right) \text{ și } df = n+m-2.$$

Repartiția 0: $f(t|H_0)$ este pdf a lui $T \sim t(df)$, repartiția t cu $df = n+m-2$ grade de libertate.

Valoarea p :

$$\begin{aligned}\text{Bilaterală:} & p = P(|T| > |t|) = 2 * (1 - \text{pt}(\text{abs}(t), df)); \\ \text{unilaterală mai mare:} & p = P(T > t) = 1 - \text{pt}(t, df); \\ \text{unilaterală mai mică:} & p = P(T < t) = \text{pt}(t, df).\end{aligned}$$

Codul R: Funcția din R `t.test` va rula un test t cu 2 selecții cu dispersii egale setând argumentul `var.equal=TRUE`.

Exemplul 4. Vezi exemplul 3 din a 2-a parte a cursului 16.

Observații. 1. Cel mai adesea testul este făcut cu $\mu_0 = 0$. Adică, ipoteza 0 este că **mediile sunt egale**, i.e. $\mu_x - \mu_y = 0$.

2. Dacă datele x și y au aceeași lungime, n , atunci formula pentru s_p^2 devine mai simplă:

$$s_p^2 = \frac{s_x^2 + s_y^2}{n}.$$

Cazul dispersiilor inegale

Există o formă a testului t pentru cazul **când dispersiile nu sunt presupuse egale**. Uneori este numit **testul t al lui Welch**.

Acesta arată exact la fel cu excepția unor mici schimbări în presupuneri și în formula dispersiei combinate:

Utilizare: Testăm dacă mediile populației din 2 populații diferă printr-o cantitate ipotetică.

Date: x_1, x_2, \dots, x_n și y_1, y_2, \dots, y_m .

Presupuneri: Ambele grupe de date sunt selecții normale independente:

$$\begin{aligned}x_i &\sim N(\mu_x, \sigma_x^2), \\y_j &\sim N(\mu_y, \sigma_y^2),\end{aligned}$$

unde atât μ_x cât și μ_y sunt necunoscute și posibil diferite. Dispersiile σ_x^2 și σ_y^2 sunt necunoscute și **nu sunt presupuse a fi egale**.

H_0, H_A : Exact aceleași ca în cazul dispersiilor egale.

Statistica testului: $t = \frac{\bar{x} - \bar{y} - \mu_0}{s_p}$, unde s_x^2 și s_y^2 sunt dispersiile de selecție ale datelor x , respectiv y și s_p^2 este (uneori numită) dispersia de selecție combinată:

$$s_p^2 = \frac{s_x^2}{n} + \frac{s_y^2}{m} \text{ și } df = \frac{(s_x^2/n + s_y^2/m)^2}{(s_x^2/n)^2/(n-1) + (s_y^2/m)^2/(m-1)}.$$

Repartiția 0: $f(t|H_0)$ este pdf a lui $T \sim t(df)$, repartiția t cu df grade de libertate.

Valoarea p : Exact aceeași ca în cazul dispersiilor egale.

Codul R: Funcția din R `t.test` va rula un test t în acest caz setând argumentul `var.equal=FALSE`.

Testul t cu 2 selecții în perechi

Când datele vin firesc în perechi (x_i, y_i) , putem folosi **testul t cu 2 selecții în perechi** (după de verificăm că presupunerile sunt valide!)

Exemplul 5. Pentru a măsura eficiența unei medicații de scăderea colesterolului, putem testa fiecare subiect înainte și după tratamentul cu medicamentul. Deci pentru fiecare subiect avem o pereche de măsurători: $x_i =$ nivelul de colesterol înainte de tratament și $y_i =$ nivelul de colesterol după

tratament.

Exemplul 6. Pentru a măsura eficiența unui tratament pentru cancer putem pune în pereche fiecare subiect care a primit tratamentul cu unul care nu l-a primit. În acest caz am vrea să punem în perechi subiecții care sunt similari în termeni de stadiu al bolii, vârstă, sex, etc.

Utilizare: Testăm dacă diferența medie dintre valorile perechilor dintr-o populație este egală cu o valoare ipotetică.

Date: x_1, x_2, \dots, x_n și y_1, y_2, \dots, y_n trebuie să aibă aceeași lungime.

Presupuneri: Diferențele $w_i = x_i - y_i$ sunt independente dintr-o repartiție normală $N(\mu, \sigma^2)$, unde μ și σ sunt necunoscute.

OBSERVAȚIE: Acesta este chiar un test t de o selecție folosind w_i .

H_0 : Pentru un μ_0 specificat, $\mu = \mu_0$.

H_A :

Bilaterală: $\mu \neq \mu_0$;

unilaterală mai mare: $\mu > \mu_0$;

unilaterală mai mică: $\mu < \mu_0$.

Statistica testului: $t = \frac{\bar{w} - \mu_0}{s/\sqrt{n}}$,

unde s^2 este dispersia de selecție: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (w_i - \bar{w})^2$.

Repartiția 0: $f(t|H_0)$ este pdf a lui $T \sim t(n-1)$ (repartiția t a lui Student cu $n-1$ grade de libertate).

Valoarea p :

Bilaterală: $p = P(|T| > |t|) = 2 * (1 - \text{pt}(\text{abs}(\mathbf{t}), \mathbf{n} - 1));$

unilaterală mai mare: $p = P(T > t) = 1 - \text{pt}(\mathbf{t}, \mathbf{n} - 1);$

unilaterală mai mică: $p = P(T < t) = \text{pt}(\mathbf{t}, \mathbf{n} - 1).$

Cod R: Funcția `t.test` din R va face un test cu 2 selecții în perechi dacă punem argumentul `paired=TRUE`. Putem de asemenea să facem un test t de o selecție pentru $x - y$.

Exemplul 7. Acest exemplu este din John Rice, *Mathematical Statistics and Data Analysis*, 2nd edition, p. 412.

Pentru a studia efectul fumatului asupra agregării trombocitelor, P.H. Levine (An acute effect of cigarette smoking on platelet function, *Circulation*, 48, 619-623, 1973) a luat sânge de la 11 subiecți înainte și după ce au fumat o țigară și a măsurat gradul în care trombocitele s-au agregat. Iată datele:

Before	25	25	27	44	30	67	53	53	52	60	28
After	27	29	37	56	46	82	57	80	61	59	43
Difference	2	4	10	12	16	15	4	27	9	-1	15

Ipoteza 0 este că fumatul nu a avut efect asupra agregării trombocitelor, i.e. diferența ar trebui să aibă media $\mu_0 = 0$. Iată codul R pentru un test t cu 2 selecții pentru a testa această ipoteză:

```
before.cig=c(25,25,27,44,30,67,53,53,52,60,28)
after.cig=c(27,29,37,56,46,82,57,80,61,59,43)
t.test(after.cig,before.cig,mu=0,paired=TRUE)
```

Iată rezultatul:

Paired t-test

```
data: after.cig and before.cig
t = 4.2716, df = 10, p-value = 0.001633
alternative hypothesis: true difference in means is not equal to
0
95 percent confidence interval:
4.91431 15.63114
sample estimates:
mean of the differences
10.27273
Obțineam aceleași rezultate cu testul  $t$  de o selecție:
t.test(after.cig-before.cig,mu=0)
```

1.4.4 ANOVA unidirecțională (Testul F pentru medii egale)

Utilizare: Testăm dacă mediile populațiilor din n grupe coincid.

Date (n grupe, m date din fiecare grup)

$$\begin{array}{cccc} x_{11}, & x_{12}, & \dots, & x_{1m} \\ x_{21}, & x_{22}, & \dots, & x_{2m} \\ & & \dots & \\ x_{n1}, & x_{n2}, & \dots, & x_{nm} \end{array}$$

Presupuneri: Datele pentru fiecare grup sunt independente normale din repartiții cu medii (posibil) diferite, dar **aceeași dispersie**:

$$\begin{array}{l} x_{1j} \sim N(\mu_1, \sigma^2) \\ x_{2j} \sim N(\mu_2, \sigma^2) \\ \dots \\ x_{nj} \sim N(\mu_n, \sigma^2) \end{array}$$

Mediile grupurilor μ_i sunt necunoscute și posibil diferite. Dispersia σ este cunoscută, dar aceeași pentru toate grupurile.

H_0 : Toate mediile sunt identice $\mu_1 = \mu_2 = \dots = \mu_n$.

H_A : Nu toate mediile sunt egale.

Statistica testului: $w = \frac{MS_B}{MS_W}$, unde

$$\begin{aligned}\bar{x}_i &= \text{media grupului } i \\ &= \frac{x_{i1} + x_{i2} + \dots + x_{im}}{m}.\end{aligned}$$

\bar{x} = media tuturor datelor.

$$\begin{aligned}s_i^2 &= \text{dispersia de selecție a grupului } i \\ &= \frac{1}{m-1} \sum_{j=1}^m (x_{ij} - \bar{x}_i)^2.\end{aligned}$$


$$\begin{aligned}MS_B &= \text{dispersia între grupuri} \\ &= m \cdot \text{dispersia de selecție a mediilor grupurilor} \\ &= \frac{m}{n-1} \sum_{i=1}^n (\bar{x}_i - \bar{x})^2.\end{aligned}$$

$$\begin{aligned}MS_W &= \text{media dispersiilor grupurilor} \\ &= \text{media de selecție a } s_1^2, \dots, s_n^2 \\ &= \frac{s_1^2 + s_2^2 + \dots + s_n^2}{n}.\end{aligned}$$

Ideea: Dacă μ_i sunt toate egale, acest raport ar trebui să fie aproape de 1. Dacă ele nu sunt egale, atunci MS_B ar trebui să fie mai mare, în timp ce MS_W ar trebui să rămână cam aceeași, deci w ar trebui să fie mai mare.

Repartiția 0: $f(w|H_0)$ este pdf a lui $W \sim F(n-1, n(m-1))$.

Aceasta este repartiția F cu $n-1$ și $n(m-1)$ grade de libertate. Câteva repartiții F sunt reprezentate astfel:



Valoarea p : $p = P(W > w) = 1 - \text{pf}(w, n-1, n(m-1))$.

Observații. 1. ANOVA testează dacă toate mediile sunt egale. Nu testează

dacă unele din medii sunt egale.

2. Există un test unde dispersiile nu sunt presupuse egale.

3. Există un test unde grupurile nu au toate același număr de date.

4. R are o funcție `aov()` pentru teste ANOVA. Vezi:

<https://personality-project.org/r/r.guide/r.anova.html#oneway>

<http://en.wikipedia.org/wiki/F-test>.

Exemplul 8. Tabelul arată nivelul de durere perceput de pacienți (pe o scară de la 1 la 6) după 3 proceduri medicale diferite.

T_1	T_2	T_3
2	3	2
4	4	1
1	6	3
5	1	3
3	4	5

(1) Faceți un test F care să compare mediile acestor tratamente.

(2) Bazându-vă pe test, ce puteți concluziona despre tratamente?

Răspuns. Folosind codul de mai jos, statistica F este 0.325 și valoarea p este 0.729. La orice nivel rezonabil de semnificație nu respingem ipoteza 0 că nivelul mediu de durere este același pentru toate 3 tratamentele.

Nu este rezonabil să concluzionăm că ipoteza 0 este adevărată. Cu doar 5 date pe procedură ne poate lipsi puterea de a distinge mediile diferite.

Codul R pentru test

```
# DATE ----
```

```
T1=c(2,4,1,5,3)
```

```
T2=c(3,4,6,1,4)
```

```
T3=c(2,1,3,3,5)
```

```
procedure=c(rep('T1',length(T1)),rep('T2',length(T2)),rep('T3',length(T3)))
```

```
pain=c(T1,T2,T3)
```

```
data.pain=data.frame(procedure,pain)
```

```
aov.data=aov(pain~procedure,data=data.pain) # face analiza dispersiei
```

```
print(summary(aov.data))# arată tabelul rezumatului
```

Rezumatul arată o valoare p (arătată ca $\Pr(>F)$) de 0.729. De aceea nu respingem ipoteza 0 că toate 3 mediile sunt egale.

1.4.5 Testul χ^2 pentru bunătatea potrivirii

Acesta este un test despre cât de bine o repartiție de probabilitate ipotetică se potrivește cu datele. Statistica testului este numită **statistică χ^2** și repartiția

0 asociată statisticii χ^2 este [repartiția \$\chi^2\$](#) . Ea este notată cu $\chi^2(df)$, unde parametrul df este numărul de [grade de libertate](#).

Presupunem că avem o funcție masă de probabilitate necunoscută dată de următorul tabel.

Outcomes	ω_1	ω_2	\dots	ω_n
Probabilities	p_1	p_2	\dots	p_n

În testul χ^2 pentru bunătatea potrivirii ipoteza este o mulțime de valori pentru probabilități. Tipic, ipoteza este că probabilitățile au o repartiție cunoscută cu anumiți parametri, de exemplu binomială, Poisson, multinomială. Apoi testul încearcă să determine dacă această mulțime de probabilități ar fi putut genera rezonabil datele colectate.

Utilizare: Testăm dacă date discrete se potrivesc cu o anumită funcție masă de probabilitate finită.

Date: Câte un număr observat O_i pentru fiecare rezultat posibil ω_i .

Presupuneri: Niciuna.

H_0 : Datele provin dintr-o anumită repartiție discretă.

H_A : Datele provin dintr-o repartiție diferită.

Statistica testului: Datele constau din numerele observate O_i pentru fiecare ω_i . Din tabelul de probabilitate al ipotezei 0 obținem o mulțime de numere așteptate E_i . Sunt 2 statistici pe care le putem folosi:

$$\text{Statistica raportului de verosimilitate } G = 2 \sum O_i \ln \left(\frac{O_i}{E_i} \right)$$

$$\text{Statistica } \chi^2 \text{ a lui Pearson } X^2 = \sum \frac{(O_i - E_i)^2}{E_i}.$$

Există o teoremă că sub ipoteza 0 $X^2 \approx G$ și ambele sunt aproximativ χ^2 . Înainte de calculatoare, X^2 era folosită deoarece era mai ușor de calculat. Acum, este mai bine să folosim G deși încă veți vedea X^2 folosită destul de des.

Grade de libertate df : Pentru testele χ^2 numărul gradelor de libertate poate fi un pic complicat. În acest caz $df = n - 1$. Este calculat ca numărul de celule care pot fi completate liber în concordanță cu statisticile folosite pentru a calcula numerele așteptate din celule presupunând H_0 .

Repartiția 0: Presupunând H_0 , ambele statistici au (aproximativ) o repartiție χ^2 cu df grade de libertate. Adică atât $f(G|H_0)$ cât și $f(X^2|H_0)$ au aceeași pdf ca $Y \sim \chi^2(df)$.

Valoarea p :

$$\begin{aligned} p &= P(Y > G) &= 1 - \text{pchisq}(G, df) \\ p &= P(Y > X^2) &= 1 - \text{pchisq}(X^2, df) \end{aligned}$$

Codul R: Funcția R `chisq.test` poate fi folosită pentru a face calcule pentru un test χ^2 folosind X^2 . Pentru G , trebuie să facem calculele "cu mâna" (ajutați de R) sau să găsim un pachet care are o funcție. (Probabil va fi numită `likelihood.test` sau `G.test`.)

Observație. Când statistica raportului de verosimilitate G este folosită, testul este de asemenea numit **test G** sau **testul raportului de verosimilitate**.

Exemplul 9. Primul exemplu χ^2 . Presupunem că avem un experiment care produce date numerice. Pentru acest experiment rezultatele posibile sunt 0, 1, 2, 3, 4, 5 sau mai mult. Facem 51 de încercări și numărăm frecvența fiecărui rezultat, obținând următoarele date:

Outcomes	0	1	2	3	4	≥ 5
Observed counts	3	10	15	13	7	3

Presupunem că ipoteza noastră H_0 este că datele provin din 51 de încercări ale repartiției binomiale(8,0.5) și ipoteza noastră alternativă H_A este că datele provin dintr-o altă repartiție.

1. Faceți un tabel al numerelor observate și așteptate.
2. Calculați statistica raportului de verosimilitate G și statistica χ^2 a lui Pearson X^2 .
3. Calculați numărul de grade de libertate ale repartiției 0.
4. Calculați valorile p corespunzătoare lui G și X^2 .

Răspuns. 1. Presupunând H_0 , datele provin dintr-o repartiție binomială(8,0.5). Avem 51 de observații, deci numărul așteptat pentru fiecare rezultat este 51 · probabilitatea lui. Folosind R se obține:

Rezultate	0	1	2	3	4	≥ 5
Numere observate	3	10	15	13	7	3
Probabilități H_0	0.00390625	0.03125	0.109375	0.21875	0.2734375	0.3632812
Numere așteptate	0.1992188	1.59375	5.578125	11.15625	13.9453125	18.52734

2. Folosind formulele de mai sus calculăm $X^2 = 116.4056$ și $G = 66.08122$.
3. Singura statistică folosită în calculul numerelor așteptate a fost numărul total de observații 51. Deci, numărul de grade de libertate este 5, i.e. putem pune 5 dintre numerele din celule liber și ultimul este determinat de cerința ca totalul să fie 51.
4. Valorile p sunt $p_G = 1 - \text{pchisq}(G, 5)$ și $p_{X^2} = 1 - \text{pschisq}(X^2, 5)$. Ambele valori p sunt efectiv 0. Pentru aproape orice nivel de semnificație respingem H_0 în favoarea H_A .

Exemplul 10. (Grade de libertate.) Presupunem că avem aceleași date ca în exemplul precedent, dar ipoteza 0 a noastră este că datele vin din încercări independente ale repartiției binomiale(8, θ), unde θ poate fi oricât între 0 și 1. H_A este că datele vin dintr-o altă repartiție. În acest caz trebuie să estimăm

θ din date, de exemplu folosind MLE. În total am calculat 2 valori din date: numărul total de date și estimarea lui θ . Deci, numărul de grade de libertate este $6 - 2 = 4$.

Exemplul 11. Experimentele genetice ale lui Mendel. (Adaptat din Rice, *Mathematical Statistics and Data Analysis*, 2nd ed., exemplul C, p. 314).

În unul din experimentele lui pe mazăre, Mendel a încrucișat 556 masculi netezi, galbeni cu femele verzi zbârcite. Presupunând că genele netede și zbârcite apar cu frecvență egală ne-am aștepta ca $1/4$ din populația de mazăre să aibă 2 gene netede (SS), $1/4$ să aibă 2 gene zbârcite (ss) și $1/2$ rămasă să fie heterozigoți Ss . De asemenea așteptăm aceste fracții pentru gene galbene (Y) și verzi (y). Dacă genele de culoare și netezime sunt moștenite independent și cele netede și galbene sunt ambele dominante ne-am aștepta la următorul tabel de frecvențe pentru fenotipuri.

	Yellow	Green	
Smooth	9/16	3/16	3/4
Wrinkled	3/16	1/16	1/4
	3/4	1/4	1

Tabelul de probabilitate pentru ipoteza 0

Deci, din 556 de încrucișări, numărul așteptat de păstăi netede galbene este $556 \cdot 9/16 = 312.75$. Analog pentru celelalte posibilități. Iată un tabel care dă numerele observate și așteptate din experimentele lui Mendel.

	Observed count	Expected count
Smooth yellow	315	312.75
Smooth green	108	104.25
Wrinkled yellow	102	104.25
Wrinkled green	31	34.75

Ipoteza 0 este că numerele observate sunt selecții aleatoare repartizate conform tabelului de frecvențe de mai sus. Folosim numerele să calculăm statisticile noastre.

Statistica raportului de verosimilitate este

$$\begin{aligned}
G &= 2 \sum O_i \ln \left(\frac{O_i}{E_i} \right) \\
&= 2 \left(315 \ln \left(\frac{315}{312.75} \right) + 108 \ln \left(\frac{108}{104.25} \right) + 102 \ln \left(\frac{102}{104.25} \right) + 31 \ln \left(\frac{31}{34.75} \right) \right) \\
&= 0.6184391.
\end{aligned}$$

Statistica χ^2 a lui Pearson este

$$\begin{aligned}
X^2 &= \sum \frac{(O_i - E_i)^2}{E_i} \\
&= \frac{(315 - 312.75)^2}{312.75} + \frac{(108 - 104.25)^2}{104.25} + \frac{(102 - 104.25)^2}{104.25} + \frac{(31 - 34.75)^2}{34.75} \\
&= 0.6043165.
\end{aligned}$$

Cele 2 statistici sunt foarte apropiate. Acesta este cazul de obicei. În general statistica raportului de verosimilitate este mai robustă și ar trebui preferată. Numărul de grade de libertate este 3, deoarece sunt 4 cantități observate și o relație între ele: suma lor este 556. Deci, sub ipoteza 0, G are o repartiție $\chi^2(3)$. Folosind **R** pentru a calcula valoarea p obținem

$$p = 1 - \text{pchisq}(0.6184391, 3) = 0.8921985.$$

Nu vom respinge ipoteza 0 la orice nivel rezonabil de semnificație. Valoarea p folosind statistica lui Pearson este 0.8954435 - aproape identică.

1.4.6 Testul χ^2 pentru omogenitate

Acesta este un test pentru a vedea dacă unele seturi independente de date provin din aceeași repartiție. (Înțelesul omogenității în acest caz este că toate repartițiile sunt aceleași.)

Utilizare: Testăm dacă m mulțimi independente de date discrete provin din aceeași repartiție.

Rezultate: $\omega_1, \omega_2, \dots, \omega_n$ sunt rezultate posibile. Acestea sunt aceleași pentru fiecare set de date.

Date: Presupunem m seturi independente de date dând numere pentru fiecare rezultat posibil. Adică, pentru setul de date i avem un număr observat O_{ij} pentru fiecare rezultat posibil ω_j .

Presupuneri: Niciuna.

H_0 : Fiecare set de date provine din aceeași repartiție. (Nu specificăm care este această repartiție.)

H_A : Seturile de date nu provin din aceeași repartiție.

Statistica testului: Vezi exemplul de mai jos. Sunt mn celule conținând numerele pentru fiecare rezultat pentru fiecare set de date. Folosind Repartiția 0 putem estima numerele așteptate pentru fiecare din seturile de date. Statisticile X^2 și G sunt calculate exact ca mai sus.

Numărul de grade de libertate $df = (m - 1)(n - 1)$. (Vezi exemplul de mai jos.)

Repartiția 0: $\chi^2(df)$. Valorile p sunt calculate ca în testul χ^2 pentru bunătatea potrivirii.

Codul R: Funcția R `chisq.test` poate fi folosită pentru a face calcule pentru un test χ^2 folosind X^2 . Pentru G , trebuie să facem calculele "cu mâna" (ajutați de R) sau să găsim un pachet care are o funcție. (Probabil va fi numită `likelihood.test` sau `G.test`.)

Exemplul 12. Cineva pretinde că a găsit o piesă de teatru pierdută de mult a lui William Shakespeare. Vă cere să testați dacă piesa a fost sau nu scrisă de Shakespeare.

Mergeți la <http://www.opensourceshakespeare.org> și alegeți aleator 12 pagini din *Regele Lear* și numărați folosirea cuvintelor uzuale. Faceți același lucru pentru "piesa pierdută de mult". Obțineți următorul tabel.

Word	a	an	this	that
<i>King Lear</i>	150	30	30	90
Long lost work	90	20	10	80

Folosind aceste date, faceți un test de semnificație pentru pretenția că piesa pierdută de mult este de William Shakespeare. Folosiți un nivel de semnificație de 0.1.

Răspuns. H_0 : Pentru cele 4 cuvinte numărate piesa pierdută de mult are aceleași frecvențe relative ca numerele luate din *Regele Lear*.

Totalul cuvintelor numărate în ambele piese este 500, deci estimarea de verosimilitate maximă a frecvențelor relative presupunând H_0 este numărul total pentru fiecare cuvânt împărțit la 500.

Word	a	an	this	that	Total count
<i>King Lear</i>	150	30	30	90	300
Long lost work	90	20	10	80	200
totals	240	50	40	170	500
rel. frequencies under H_0	240/500	50/500	40/500	170/500	500/500

Acum, numerele așteptate pentru fiecare piesă sub H_0 sunt numerele totale pentru acea piesă înmulțite cu frecvențele relative din tabelul de mai sus. Următorul tabel dă numerele: (observate, așteptate) pentru fiecare piesă. Pe

ultima linie, în loc de "249" se va citi "240".

Word	a	an	this	that	Totals
<i>King Lear</i>	(150, 144)	(30, 30)	(30, 24)	(90, 102)	(300, 300)
Long lost work	(90, 96)	(20, 20)	(10, 16)	(80, 68)	(200, 200)
Totals	(249, 240)	(50, 50)	(40, 40)	(170, 170)	(500, 500)

Statistica χ^2 este

$$\begin{aligned}
 X^2 &= \sum \frac{(O_i - E_i)^2}{E_i} \\
 &= \frac{6^2}{144} + \frac{0^2}{30} + \frac{6^2}{24} + \frac{12^2}{102} + \frac{6^2}{96} + \frac{0^2}{20} + \frac{6^2}{16} + \frac{12^2}{68} \\
 &\approx 7.904412.
 \end{aligned}$$

Sunt 8 celule și toate numerele marginale sunt fixate deoarece a fost nevoie de ele pentru a determina numerele așteptate. Am putea să punem liber valorile din 3 celule din tabel, de exemplu cele 3 celule albastre, apoi restul celulelor sunt determinate pentru a face corecte totalele marginale. Astfel, $df = 3$. (Sau ne puteam reaminti că $df = (m - 1)(n - 1) = 3 \cdot 1 = 3$, unde m este numărul de coloane și n este numărul de linii.)

Folosind R găsim $1 - \text{pchisq}(7.904412, 3) = 0.04802909$. Deoarece aceasta este mai mică decât nivelul nostru de semnificație de 0.1, respingem ipoteza 0 că frecvențele relative ale cuvintelor sunt aceleași în ambele piese.

Dacă facem în plus presupunerea că toate piesele lui Shakespeare au frecvențe similare ale cuvintelor (ceea ce este ceva ce putem verifica) concluzionăm că piesa pierdută probabil nu este a lui Shakespeare.

2 Comparație între deducțiile frecvenționistă și Bayesiană

2.1 Scopul învățării

Să poată să explice diferența dintre valoare p și probabilitate a posteriori unui doctor.

2.2 Introducere

Am aflat despre cele 2 școli de deducție statistică: Bayesiană și frecvenționistă. Ambele abordări permit evaluarea dovezilor despre ipoteze concurente.

2.3 Formula lui Bayes ca piatră de încercare

Formula lui Bayes este o propoziție abstractă despre probabilități condiționate ale evenimentelor:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}.$$

Am început deducția Bayesiană reinterpretând evenimentele din formula lui Bayes:

$$P(\mathcal{H}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathcal{H})P(\mathcal{H})}{P(\mathcal{D})}.$$

Acum \mathcal{H} este o ipoteză și \mathcal{D} sunt datele care pot da dovezi pentru sau împotriva lui \mathcal{H} . Fiecare termen din formula lui Bayes are un nume și un rol. A priori $P(\mathcal{H})$ este probabilitatea ca \mathcal{H} să fie adevărată înainte de considerarea datelor.

A posteriori $P(\mathcal{H}|\mathcal{D})$ este probabilitatea ca \mathcal{H} să fie adevărată după considerarea datelor.

Verosimilitatea $P(\mathcal{D}|\mathcal{H})$ este dovada despre \mathcal{H} furnizată de datele \mathcal{D} .

$P(\mathcal{D})$ este probabilitatea totală a datelor luând în considerare toate ipotezele posibile.

Dacă a priori și verosimilitatea sunt cunoscute pentru toate ipotezele, atunci formula lui Bayes calculează a posteriori exact. Acesta a fost cazul când am aruncat un zar selectat aleator dintr-o urnă [al cărei conținut îl știam](#). Numim aceasta logica deductivă a teoriei probabilităților și ea dă un mod direct de a compara ipotezele, a trage concluzii și a lua decizii.

În cele mai multe experimente, probabilitățile a priori ale ipotezelor nu sunt cunoscute. În acest caz, recurgem la arta deducției statistice: ori inventăm o a priori (Bayesianii), ori facem tot ce putem folosind doar verosimilitatea (frecvenționiștii).

Școala Bayesiană modelează incertitudinea printr-o repartiție de probabilitate peste ipoteze. Abilitatea cuiva de a face deducții depinde de gradul de încredere în a priori aleasă și robustețea constatărilor pentru a alterna repartițiile a priori poate fi relevantă și importantă.

Școala frecvenționistă folosește doar repartiții condiționate ale datelor cunoscând ipoteze specifice. Presupunerea este că o ipoteză (parametru specificând repartiția condiționată a datelor) este adevărată și că datele observate provin din acea repartiție. În particular, abordarea frecvenționistă nu depinde de o a priori subiectivă care poate varia de la un investigator la altul.

Aceste 2 școli pot fi comparate mai departe după cum urmează:

Deducția Bayesiană

folosește probabilități atât pentru ipoteze cât și pentru date;
depinde de a priori și verosimilitatea datelor observate;

cere să se știe sau să se construiască o "a priori subiectivă";
a dominat practica statistică înainte de secolul 20;
poate fi intens calculată din cauza integrării peste mulți parametri.

Deductia frecvenționistă (NHST)

nu folosește niciodată probabilitatea unei ipoteze (nu a priori sau a posteriori);

depinde de verosimilitatea $P(\mathcal{D}|\mathcal{H})$ atât pentru datele observate cât și pentru cele neobservate;

nu cere o a priori;

practica statistică dominantă de-a lungul secolului 20;

tinde să fie mai puțin intensă din punctul de vedere al calculelor.

Măsurile frecvenționiste ca valori p sau intervale de încredere continuă să domine cercetarea, în special în științele vieții. Totuși, în era actuală a computerelor puternice și datelor mari, metodele Bayesiene au avut o renaștere enormă în domenii ca învățarea automată și genetica. Acum sunt un număr de studii clinice mari, în curs de desfășurare folosind protocoale Bayesiene, ceea ce ar fi fost greu de imaginat cu o generație în urmă.

În timp ce împărțirile profesionale rămân, consensul care se formează printre statisticienii de top este că cea mai eficace abordare a problemelor complexe adesea folosește cele mai bune perspective din ambele școli lucrând împreună.

2.4 Critici și apărări

2.4.1 Critica deducției Bayesiene

1. Principala critică a deducției Bayesiene este că o a priori este subiectivă. Nu există o singură metodă de a alege a priori, deci persoane diferite pot produce a priori diferite și de aceea pot ajunge la a posteriori și concluzii diferite.
2. Mai departe, sunt obiecții filozofice la atribuirea de probabilități ipotezelor, deoarece ipotezele nu sunt rezultate ale experimentelor repetabile în care se poate măsura frecvența pe termen lung. Mai degrabă, o ipoteză este ori adevărată ori falsă, indiferent dacă se știe care este cazul. O monedă este ori corectă, ori incorectă; tratamentul 1 este ori mai bun, ori mai rău ca tratamentul 2; soarele va răsări sau nu va răsări mâine.

2.4.2 Apărarea deducției Bayesiene

1. Probabilitatea ipotezelor este exact ce ne trebuie pentru a lua decizii. Când doctorul îmi spune că un test a ieșit pozitiv vreau să știu care este probabilitatea că aceasta înseamnă că sunt bolnav. Adică, vreau să știu probabilitatea ipotezei "Sunt bolnav".

2. Folosirea teoremei lui Bayes este riguroasă logic. Odată ce avem a priori toate calculele noastre au certitudinea logicii deductive.
3. Încercând diferite a priori, putem vedea cât de sensibile sunt rezultatele noastre de alegerea a priori.
4. Este ușor de comunicat un rezultat încadrat în termeni de probabilitățile ipotezelor.
5. Chiar dacă a priori pot fi subiective, se pot specifica presupunerile folosite pentru a ajunge la ele, care permit altor oameni să le folosească sau să încerce alte a priori.
6. Dovezile derivate din date sunt independente de noțiuni despre "datele mai extreme", care depind de schema experimentală exactă.
7. Datele pot fi folosite pe măsură ce vin. Nu există o cerință ca fiecare contingent să fie planificat înainte.

2.4.3 Critica deducției frecvenționiste

1. Este ad-hoc și nu are forța logicii deductive. Noțiuni ca "date mai extreme" nu sunt bine definite. Valoarea p depinde de schema experimentală exactă.
2. Experimentele trebuie complet specificate înainte. Aceasta poate conduce la rezultate aparent paradoxale. Vezi "istoria voltmetrului" în: http://en.wikipedia.org/wiki/Likelihood_principle.
3. Valoarea p și nivelul de semnificație sunt notoriu predispuse la interpretare greșită. Un nivel de semnificație de 0.05 înseamnă că probabilitatea unei erori de tipul I este 5%. Adică, *dacă ipoteza 0 este adevărată*, atunci în 5% din timp va fi respinsă din cauza caracterului aleatoriu. Mulți oameni gândesc eronat că o valoare p de 0.05 înseamnă că probabilitatea ipotezei 0 este 5%. Ați putea argumenta că aceasta nu este o critică a deducției frecvenționiste ci, mai degrabă, o critică a ignoranței populare. Totuși, subtilitatea ideilor contribuie sigur la problemă.

2.4.4 Apărarea deducției frecvenționiste

1. Este obiectivă: toți statisticienii vor fi de acord cu valoarea p . Orice individ poate apoi decide dacă valoarea p garantează respingerea ipotezei 0.
2. Testarea ipotezei folosind testarea semnificației frecvenționistă este aplicată în analiza statistică a investigațiilor științifice, evaluând puterea dovezilor împotriva unei ipoteze 0 cu date. Interpretarea rezultatelor este lăsată utilizatorului testelor. Diferiți utilizatori pot aplica diferite nivele de semnificație pentru a determina semnificația statistică. Statistica frecvenționistă nu pretinde că dă un mod de a alege un nivel de semnificație; mai degrabă descrie explicit

compromisul între erorile de tipul I și de tipul II.

3. Proiectarea experimentului frecvenționistă cere o descriere atentă a experimentului și metodelor de analiză înaintea startului. Aceasta ajută controlul pentru părtinirea experimentatorului.

4. Abordarea frecvenționistă a fost folosită de peste 100 de ani și am văzut progres științific extraordinar. Cu toate că frecvenționistul însuși n-ar pune o probabilitate pe încrederea că metodele frecvenționiste sunt valoroase, n-ar trebui ca această istorie să dea Bayesianului o încredere a priori puternică în utilitatea metodelor frecvenționiste?

2.5 Fiți atenți la p -urile voastre

Facem un test t cu 2 selecții pentru medii egale, cu $\alpha = 0.05$ și obținem o valoare p de 0.04. Care sunt șansele ca cele 2 selecții să provină din repartiții cu aceeași medie?

(a) 19/1 (b) 1/19 (c) 1/20 (d) 1/24 (e) necunoscute.

Răspuns. (e) necunoscute. Metodele frecvenționiste dau doar probabilități ale statisticilor condiționate de ipoteze. Ele nu dau probabilități ale ipotezelor.

2.6 Reguli de oprire

Când derulăm o serie de încercări, avem nevoie de o regulă despre când să ne oprim. 2 reguli uzuale sunt:

1. Facem exact n încercări și ne oprim.
2. Facem încercări până vedem un rezultat și apoi ne oprim.

În acest exemplu vom considera 2 experimente de aruncarea monedei.

Experimentul 1: Aruncăm moneda exact de 6 ori și raportăm numărul aversurilor.

Experimentul 2: Aruncăm moneda până apare primul revers și raportăm numărul aversurilor.

Jon este îngrijorat că moneda lui este deplasată spre aversuri, deci, înainte s-o utilizeze la cursuri, el îi testează corectitudinea. El face un experiment și raportează lui Jerry că secvența lui de aruncări a fost $HHHHHT$. Dar Jerry nu este atent și uită ce experiment a făcut Jon să producă datele.

Abordarea frecvenționistă

Deoarece a uitat ce experiment a făcut Jon, Jerry frecvenționistul decide să calculeze valorile p pentru ambele experimente cunoscând datele lui Jon.

Fie θ probabilitatea aversului. Avem ipotezele 0 și alternativă unilaterală

$$H_0 : \theta = 0.5, \quad H_A : \theta > 0.5.$$

Experimentul 1: Repartiția 0 este binomială(6, 0.5) deci valoarea p unilaterală este probabilitatea a 5 sau 6 aversuri în 6 aruncări. Folosind R obținem

$$p = 1 - \text{pbinom}(4, 6, 0.5) = 0.109375.$$

Experimentul 2: Repartiția 0 este geometrică(0.5) deci, valoarea p unilaterală este probabilitatea a 5 sau mai multe aversuri înaintea primului revers. Folosind R obținem

$$p = 1 - \text{pgeom}(4, 0.5) = 0.03125.$$

Folosind nivelul de semnificație tipic de 0.05, aceleași date duc la concluzii diferite! Am respinge H_0 în experimentul 2, dar nu în experimentul 1.


Frecvenționistul nu are nicio problemă cu aceasta. Mulțimea rezultatelor este diferită pentru experimentele diferite, deci noțiunea de date extreme și de aceea, de valoare p , este diferită. De exemplu, în experimentul 1 am considera $THHHHH$ a fi la fel de extrem ca $HHHHHT$. În experimentul 2 n-am vedea niciodată $THHHHH$ deoarece experimentul s-ar termina după primul revers.

Abordarea Bayesiană.

Jerry Bayesianul știe că nu contează care dintre cele 2 experimente a fost făcut de Jon, deoarece funcțiile (coloanele) de verosimilitate binomială și geometrică pentru datele $HHHHHT$ sunt proporționale. În orice caz, el trebuie să inventeze o a priori și alege $\text{Beta}(3, 3)$. Aceasta este o a priori relativ plată concentrată peste intervalul $0.25 \leq \theta \leq 0.75$.

Vezi <http://mathlets.org/mathlets/beta-distribution>.

Deoarece repartițiile beta și binomială (sau geometrică) formează o pereche conjugată, actualizarea Bayesiană este simplă. Datele de 5 aversuri și 1 revers dau o repartiție a posteriori $\text{Beta}(8,4)$. Iată graficul a priori și a posteriori. Liniile albastre de jos sunt intervale de probabilitate 50% și 90% pentru a posteriori.



Repartițiile a priori și a posteriori cu intervale de probabilitate 0.5 și 0.9

Iată calculele relevante din R:

Interval de probabilitate 50% a posteriori:

`qbeta(c(0.25,0.75),8,4) = [0.579529, 0.7635974]`.

Interval de probabilitate 90% a posteriori:

`qbeta(c(0.05,0.95),8,4) = [0.4356258, 0.8649245]`.

$P(\theta > 0.5 | \text{date}) = 1 - \text{pbeta}(0.5, 8, 4) = 0.8867188$.

Plecând de la a priori Beta(3,3), probabilitatea a posteriori ca moneda să fie deplasată spre avers este 0.8867188.

2.7 Luarea deciziilor

Destul de des scopul deducției statistice este de a ajuta la luarea deciziilor, de exemplu dacă sau nu să fie supus unei intervenții chirurgicale, cât de mult să investească într-o acțiune, dacă sau nu să mergă să aprobească școala, etc.

În teoria deciziilor statistice, consecințele acțiunilor sunt măsurate printr-o funcție de utilitate. Funcția de utilitate atribuie o pondere fiecărui rezultat posibil; în limbajul probabilităților este pur și simplu o variabilă aleatoare.

De exemplu, în investițiile mele aș putea atribui o utilitate de d rezultatului unui câștig de d lei pe acțiune (dacă $d < 0$, utilitatea mea este negativă). Pe de altă parte, dacă toleranța mea pentru risc este mică, voi atribui mai multă utilitate negativă pentru pierderi decât pentru câștiguri (să zicem, $-d^2 - 1$ dacă $d < 0$ și d dacă $d \geq 0$).

O regulă de decizie combină utilitatea medie cu dovezile pentru fiecare ipoteză cunoscând datele (de exemplu, valori p sau repartiții a posteriori) într-un cadru statistic formal pentru luarea deciziilor.

În acest cadru, frecvenționistul va considera media utilității dată fiind o ipoteză

$$E(U|\mathcal{H}),$$

unde U este variabila aleatoare reprezentând utilitatea. Există metode frecvenționiste pentru combinarea utilității medii cu valori p ale ipotezelor pentru a ghida deciziile.

Bayesianul poate combina $E(U|\mathcal{H})$ cu a posteriori (sau a priori dacă este înaintea colectării datelor) pentru a crea o regulă de decizie Bayesiană.

În orice cadru, 2 persoane considerând aceeași investiție pot avea funcții de utilitate diferite și lua decizii diferite. De exemplu, o acțiune riscantă (cu un potențial mai mare de a fluctua) va fi mai atrăgătoare în raport cu prima funcție de utilitate de mai sus decât în raport cu a 2-a.

Un rezultat teoretic semnificativ este că pentru orice regulă de decizie există o regulă de decizie Bayesiană care este, într-un sens precis o regulă cel puțin la fel de bună.